



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO



FACULTAD DE INGENIERÍA

AnteProyecto

Minería de Datos

Grupo: 1

Equipo:

Rojas Chimal Karla Beatriz – 320048025

García Gallegos Alejandro – 423093137

Profesor: Mtro. Gerardo Gabriel Carrasco Zúñiga

Semestre: 2027-1

Fecha de entrega: 26 de septiembre de 2026

Índice

1. Objetivos	3
1.1. Objetivo General	3
1.2. Objetivos Específicos	3
2. Contexto	4
2.1. Contexto Global del Accidente Cerebrovascular	4
2.2. Descripción del Dataset	5
2.3. Justificación de la Relevancia del Dataset	6
3. Estrategia	7
3.1. Decisiones Estratégicas Clave	7
3.2. Fases del Proyecto	8
4. Problemática a Atender y Expectativas	9
4.1. Planteamiento del Problema	9
4.2. Preguntas de Investigación	9
4.3. Expectativas Cuantitativas	10
5. Plan de Trabajo: Baseline vs. Real	10
5.1. Plan Baseline	10
5.2. Plan Real	11
5.3. Tabla Comparativa Baseline vs. Real	12
6. Metodología Aplicada	13
6.1. Fase 1: Comprensión del Negocio (01_data_loading.ipynb)	13
6.2. Fase 2: Comprensión de los Datos (02_eda.ipynb)	13
6.3. Fase 3: Preparación de los Datos (03_preprocessing.ipynb)	16
6.4. Fase 4: Modelado (04_modeling.ipynb)	16
6.4.1. Modelo 1: Regresión Logística	17
6.4.2. Modelo 2: Random Forest	17
6.4.3. Estrategia de Validación	17
6.5. Fase 5: Evaluación (05_evaluation.ipynb)	17

6.6. Fase 6: Despliegue	19
7. Herramientas de Minería de Datos y Resultados	19
7.1. Herramientas Utilizadas	19
7.2. Resultados Obtenidos	21
7.2.1. Análisis Exploratorio	21
7.2.2. Desempeño de los Modelos	21
7.2.3. Importancia de Variables	22
7.3. Código Fuente y Demostración Técnica	22
8. Conclusiones	23
8.1. Logro de los Objetivos	23
8.2. Hallazgos Técnicos	23
8.3. Limitaciones y Trabajo Futuro	24
9. Fuentes Bibliográficas	24

Objetivos

Objetivo General

Desarrollar un modelo de clasificación binaria basado en técnicas de minería de datos para predecir la probabilidad de que un paciente sufra un evento cerebrovascular (*stroke*), a partir de características clínicas y sociodemográficas disponibles en atención primaria, logrando un *AUC-ROC* superior a 0.85 y un *recall* de la clase positiva superior a 0.75 sobre el conjunto de prueba.

Objetivos Específicos

- Analizar y preprocesar el *Stroke Prediction Dataset* (5,110 registros, 12 variables), identificando valores faltantes, distribuciones estadísticas y el severo desbalance de clases ($\approx 9.8\%$ positivos), aplicando las transformaciones adecuadas para garantizar la calidad del conjunto de entrenamiento.
- Realizar un análisis exploratorio de datos (EDA) exhaustivo que permita cuantificar la asociación entre cada variable predictora y la variable objetivo **stroke**, generando visualizaciones interpretables que sustenten las decisiones de ingeniería de características.
- Implementar y comparar el desempeño de al menos dos modelos de clasificación supervisada (Regresión Logística y *Random Forest*), aplicando técnicas de sobremuestreo sintético (SMOTE) para mitigar el desbalance, y seleccionar el modelo final con base en métricas orientadas al contexto médico (AUC-ROC y *recall*).
- Identificar e interpretar las variables clínicas con mayor importancia predictiva para el evento cerebrovascular, con el fin de aportar valor explicativo al modelo y facilitar su adopción en entornos clínicos reales.
- Documentar íntegramente el proceso mediante *notebooks* de Jupyter organizados secuencialmente dentro del repositorio CODIGO/, garantizando la trazabilidad y reproducibilidad de todos los experimentos realizados.

Contexto

Contexto Global del Accidente Cerebrovascular

El *stroke* o accidente cerebrovascular (ACV) es la segunda causa de muerte a nivel mundial y la principal causa de discapacidad neurológica permanente en adultos, según datos de la Organización Mundial de la Salud (OMS, 2023). Cada año se producen aproximadamente 15 millones de nuevos casos en todo el mundo; de estos, 5 millones fallecen y otros 5 millones quedan con secuelas discapacitantes permanentes, representando una carga socioeconómica estimada en cientos de miles de millones de dólares anuales en atención médica y pérdida de productividad (Feigin et al., 2021).

Fisiológicamente, el ACV se clasifica en dos grandes categorías: el **isquémico** ($\approx 87\%$ de los casos), ocasionado por la oclusión de una arteria cerebral, y el **hemorrágico** ($\approx 13\%$), producido por la ruptura de un vaso sanguíneo. En ambos casos, la privación de oxígeno y glucosa al tejido neuronal desencadena muerte celular irreversible en cuestión de minutos, de ahí que el pronóstico mejore de manera drástica con la intervención temprana (Sacco et al., 2013).

Desde la perspectiva de la salud pública, el ACV es en gran medida prevenible: hasta el 90 % de los casos se asocia a factores de riesgo modificables como hipertensión arterial, diabetes mellitus, dislipidemia, tabaquismo, fibrilación auricular, obesidad y sedentarismo (O'Donnell et al., 2016). Ello convierte a la predicción de riesgo individual en una herramienta de alto impacto para la medicina preventiva.

En México, el ACV representa la cuarta causa de muerte en la población adulta mayor de 60 años, con una tasa de mortalidad que supera las 30 defunciones por cada 100,000 habitantes. Las limitaciones en el acceso a centros especializados y la escasez de herramientas de cribado en el primer nivel de atención hacen que la mayoría de los pacientes en riesgo no sean identificados antes de sufrir el evento.

La minería de datos y el aprendizaje automático ofrecen la oportunidad de transformar los registros clínicos electrónicos en sistemas de alerta temprana de bajo costo y alta escalabilidad. Estudios recientes demuestran que modelos basados en variables de rutina (edad, presión arterial, glucosa en ayunas, IMC) alcanzan AUC-ROC

superiores a 0.80, comparables a escalas clínicas establecidas como el *Essen Stroke Risk Score* (Diener et al., 2005).

Descripción del Dataset

El conjunto de datos utilizado es el **Stroke Prediction Dataset**, publicado en Kaggle por *fedesoriano* (2021) bajo licencia de uso educativo. Contiene 5,110 observaciones de pacientes con 12 atributos clínicos y sociodemográficos, y constituye uno de los conjuntos de datos más utilizados en la literatura de aprendizaje automático aplicado a la predicción de ACV.

Las variables disponibles son:

- **id**: Identificador numérico único del paciente (no predictivo, eliminado en preprocesamiento).
- **gender**: Género del paciente (Male / Female / Other).
- **age**: Edad en años (variable continua; rango: 0.08–82 años).
- **hypertension**: Diagnóstico previo de hipertensión arterial (0 = No, 1 = Sí).
- **heart_disease**: Diagnóstico previo de enfermedad cardíaca (0 = No, 1 = Sí).
- **ever_married**: Estado civil histórico (Yes / No).
- **work_type**: Tipo de actividad laboral (Private / Self-employed / Govt_job / children / Never_worked).
- **Residence_type**: Tipo de residencia (Urban / Rural).
- **avg_glucose_level**: Nivel promedio de glucosa en sangre en mg/dL (variable continua).
- **bmi**: Índice de masa corporal (variable continua; presenta $\approx 4\%$ de valores faltantes).
- **smoking_status**: Hábito tabáquico (formerly smoked / never smoked / smokes / Unknown).

- **stroke:** Variable objetivo binaria (0 = no padeció ACV, 1 = padeció ACV).

Aspectos relevantes sobre la calidad e idoneidad del dataset:

- **Valores faltantes:** La variable `bmi` presenta 201 registros con valor nulo ($\approx 3.93\%$), que se tratan mediante imputación por la mediana.
- **Categoría desconocida:** La etiqueta `Unknown` en `smoking_status` (1,544 registros) se gestiona mediante codificación explícita como categoría propia.
- **Desbalance de clases:** Solo 498 registros (9.76%) corresponden a la clase positiva (`stroke = 1`), frente a 4,612 negativos (90.24%), configurando una proporción aproximada de 1:9.
- **Idoneidad clínica:** Todas las variables del dataset son accesibles en una consulta de atención primaria sin requerir exámenes especializados.

Cuadro 1: Resumen descriptivo del dataset

Característica	Descripción
Fuente	Kaggle — fedesoriano (2021), <i>Stroke Prediction Dataset</i>
Número de registros	5,110
Número de variables	12 (11 predictoras + 1 objetivo)
Variable objetivo	<code>stroke</code> (binaria: 0 = no ACV, 1 = ACV)
Desbalance de clases	$\approx 9.76\%$ positivos (498 / 4,612)
Valores faltantes	201 en <code>bmi</code> ($\approx 3.93\%$)
Tipo de variables	4 numéricas continuas, 7 categóricas, 1 identificador
Periodo	No especificado; uso exclusivamente educativo

Justificación de la Relevancia del Dataset

La elección de este conjunto de datos se justifica por cuatro razones fundamentales: (1) representa un problema de salud pública de alta relevancia social; (2) contiene el desbalance de clases característico de los problemas de detección de enfermedades

de baja prevalencia, forzando el uso de técnicas avanzadas de manejo de desbalance; (3) combina variables numéricas y categóricas, lo que requiere un *pipeline* de preprocesamiento completo; y (4) su tamaño reducido (5,110 registros) lo hace manejable dentro de un entorno académico sin sacrificar la complejidad metodológica.

Estrategia

Se adoptó un enfoque de **clasificación supervisada binaria**, dado que la variable objetivo (**stroke**) es discreta y sus etiquetas están disponibles para todos los registros del dataset. La metodología de referencia empleada fue **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), que proporciona un marco iterativo y cíclico estructurado en seis fases bien definidas, ampliamente adoptado tanto en entornos académicos como industriales.

Decisiones Estratégicas Clave

1. **Criterio de éxito orientado al contexto médico:** En problemas de diagnóstico, el costo de un falso negativo (paciente en riesgo no detectado) es sustancialmente mayor que el de un falso positivo. Por ello, la métrica primaria de éxito es el **recall** de la clase positiva (>0.75), seguido del **AUC-ROC** (>0.85) como indicador global de discriminación.
2. **Tratamiento del desbalance mediante SMOTE:** Dada la proporción 1:9 entre clases, se aplicó *Synthetic Minority Oversampling Technique* (SMOTE) exclusivamente sobre el conjunto de entrenamiento, respetando el límite de *data leakage* para que el conjunto de prueba mantenga la distribución real.
3. **Comparación de modelos:** Se seleccionaron dos familias de clasificadores con propiedades complementarias: (a) **Regresión Logística**, modelo lineal interpretable que sirve como *baseline* explicativo; y (b) **Random Forest**, ensamble de árboles con mayor capacidad para capturar interacciones no lineales entre variables.

4. **Validación cruzada estratificada:** Se empleó validación cruzada estratificada con $k = 5$ *folds*, garantizando que todas las particiones mantengan la proporción original de clases y estimando la variabilidad del desempeño del modelo.
5. **Trazabilidad y reproducibilidad:** Todo el código se organizó en cinco *notebooks* de Jupyter secuenciales dentro del directorio CODIGO/, con semillas aleatorias fijadas (`random_state=42`).

Fases del Proyecto

1. **Recolección y comprensión de datos:** Descarga del dataset desde Kaggle, revisión de atributos, tipos de datos, distribuciones iniciales y detección de anomalías.
2. **Preprocesamiento y limpieza:** Imputación de valores faltantes en `bmi`, codificación de variables categóricas, tratamiento del desbalance y estandarización.
3. **Exploración y análisis:** EDA con distribuciones, correlaciones y análisis bivariado respecto a la variable objetivo.
4. **Modelado:** Entrenamiento y ajuste de los clasificadores con validación cruzada estratificada ($k = 5$ *folds*).
5. **Evaluación y refinamiento:** Comparación de modelos mediante AUC-ROC, F1-score y recall; análisis de matrices de confusión y curvas ROC.
6. **Presentación de resultados:** Elaboración del reporte final y demostración técnica mediante *notebooks* interactivos.

Problemática a Atender y Expectativas

Planteamiento del Problema

El accidente cerebrovascular es una emergencia médica cuyo pronóstico mejora de manera significativa con la intervención temprana. No obstante, la gran mayoría de los pacientes en riesgo no son identificados con antelación, en parte porque las herramientas de estratificación de riesgo disponibles en el primer nivel de atención son escasas, costosas o requieren exámenes especializados fuera del alcance de muchos sistemas de salud.

Los registros clínicos electrónicos contienen información de rutina —edad, presión arterial, glucosa, IMC, antecedentes de hipertensión y cardiopatía— que, analizada con técnicas de minería de datos, puede transformarse en un sistema de alerta temprana accesible, reproducible y de bajo costo. La hipótesis central del proyecto es que este conjunto de variables de rutina es suficiente para construir un modelo predictivo con sensibilidad clínicamente útil.

El problema central se formula como: **¿Es posible predecir con suficiente sensibilidad ($\text{recall} > 0.75$) si un paciente sufrirá un stroke, utilizando únicamente variables clínicas y demográficas obtenidas en una consulta de atención primaria?**

Preguntas de Investigación

- ¿Qué combinación de variables clínicas (edad, hipertensión, glucosa, IMC, etc.) es más predictiva de un evento cerebrovascular en este dataset?
- ¿Qué modelo de clasificación supervisada ofrece el mejor equilibrio entre sensibilidad (*recall*) y precisión en un dataset con desbalance 1:9?
- ¿Cuál es el impacto cuantitativo de aplicar SMOTE sobre las métricas de recall y F1-score de los modelos evaluados?
- ¿Son los factores de riesgo identificados por el modelo consistentes con la evidencia médica publicada?

Expectativas Cuantitativas

Se establecen las siguientes metas de desempeño como criterios de éxito del proyecto:

Cuadro 2: Expectativas cuantitativas de desempeño del modelo

Métrica	Meta	Justificación
AUC-ROC	> 0.85	Indicador global de capacidad discriminativa; valores >0.80 son clínicamente útiles en modelos de riesgo cardiovascular.
Recall (clase positiva)	> 0.75	Prioridad máxima: minimizar falsos negativos (pacientes en riesgo no detectados).
F1-score	> 0.60	Balance entre precisión y recall, considerando el severo desbalance de clases.

Cualitativamente, se anticipa que las variables `age`, `avg_glucose_level` e `hypertension` serán las de mayor importancia predictiva, en línea con la evidencia médica publicada (O'Donnell et al., 2016).

Plan de Trabajo: Baseline vs. Real

Plan Baseline

El plan inicial contempló un desarrollo de cuatro semanas, distribuido de la siguiente manera:

- **Semana 1:** Descarga y familiarización con el dataset. Revisión bibliográfica sobre predicción de stroke. Definición del alcance y reparto de tareas.
- **Semana 2:** Preprocesamiento completo (imputación, codificación, manejo de desbalance) y análisis exploratorio de datos.

- **Semana 3:** Entrenamiento, ajuste y comparación de modelos de clasificación.
- **Semana 4:** Evaluación final, elaboración del reporte y preparación de la demostración técnica.

El plan baseline asumía que el preprocesamiento sería relativamente directo y que el modelado constituiría la fase más demandante. En la práctica, sin embargo, el desbalance de clases y la necesidad de validar correctamente el *pipeline* de SMOTE resultaron ser los desafíos más complejos.

Plan Real

La ejecución real del proyecto presentó variaciones respecto al plan inicial debidas a los siguientes factores:

- **Complejidad del desbalance:** El manejo correcto de SMOTE requirió investigación adicional para garantizar que el sobremuestreo se aplicara exclusivamente dentro de cada *fold* de validación cruzada mediante `imblearn.pipeline.Pipeline`, lo que añadió tiempo no previsto en la Semana 2.
- **Refinamiento iterativo del umbral de decisión:** La optimización del umbral de clasificación para maximizar el recall sin colapsar la precisión requirió iteraciones adicionales de evaluación, extendiendo la fase de modelado hasta la Semana 4.
- **Estructuración del repositorio:** La organización modular del código en cinco *notebooks* independientes y reproducibles demandó más tiempo de ingeniería del inicialmente previsto.
- **Documentación del reporte:** La redacción del documento final con rigor académico requirió una semana adicional respecto al plan original.

Tabla Comparativa Baseline vs. Real

Cuadro 3: Comparación Plan Baseline vs. Plan Real de ejecución

Actividad	Baseline	Real	Δ
Descarga y exploración inicial	Semana 1 (2 días)	Semana 1 (2 días) — sin variación	0
Revisión bibliográfica	Semana 1 (3 días)	Semana 1 (3 días) — sin variación	0
Análisis Exploratorio (EDA)	Semana 2 (3 días)	Semana 2 (4 días) — mayor profundidad	+1d
Preprocesamiento e ing. de características	Semana 2 (4 días)	Semanas 2–3 (6 días) — SMOTE pipeline	+2d
Implementación de modelos	Semana 3 (5 días)	Semana 3 (5 días) — sin variación	0
Ajuste de hiperparámetros y umbral	Semana 3 (2 días)	Semanas 3–4 (4 días) — optimización iterativa	+2d
Evaluación y análisis	Semanas 3–4 (3 días)	Semana 4 (3 días) — sin variación	0
Estructuración de repositorio	No contemplado	Semana 4 (2 días)	+2d
Redacción del reporte final	Semana 4 (3 días)	Semanas 4–5 (5 días) — mayor rigor documental	+2d
Preparación de la demostración	Semana 4 (2 días)	Semana 5 (2 días) — desplazada por sobrecarga	+7d

La principal lección aprendida es que, en proyectos con datos desbalanceados, la validación correcta del *pipeline* de balanceo consume un tiempo desproporcionado respecto a lo que sugiere la literatura introductoria. Asimismo, la modularización del código en *notebooks* reproducibles generó un valor sustancial en términos de trazabilidad y calidad.

Metodología Aplicada

El proyecto siguió íntegramente la metodología **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*), marco de referencia iterativo y agnóstico respecto a la herramienta, que estructura el ciclo de vida de un proyecto de minería de datos en seis fases (Wirth & Hipp, 2000). A continuación se describe cada fase y su correspondencia directa con los *notebooks* del directorio CODIGO/.

Fase 1: Comprensión del Negocio (01_data_loading.ipynb)

En esta fase se definió el objetivo del negocio (identificación temprana de pacientes en riesgo de ACV), se formularon los criterios de éxito cuantitativos ($\text{AUC-ROC} > 0.85$, $\text{recall} > 0.75$) y se estableció el plan de proyecto. El *notebook* 01_data_loading.ipynb documenta la carga automatizada del dataset mediante la biblioteca `kagglehub`, la inspección inicial de tipos de datos, dimensiones del dataset y una primera auditoría de valores nulos. Este archivo constituye el punto de entrada reproducible del proyecto: cualquier colaborador puede ejecutarlo en un entorno limpio y obtener el dataset en el estado exacto con el que comenzó el análisis.

Fase 2: Comprensión de los Datos (02_eda.ipynb)

El *notebook* 02_eda.ipynb implementa el Análisis Exploratorio de Datos (EDA) de forma exhaustiva. Las actividades realizadas incluyen:

- **Análisis univariado:** distribuciones de frecuencia y estadísticos descriptivos para todas las variables. Se detectaron distribuciones bimodales en `age` y `avg_glucose_level`.
- **Análisis bivariado:** tasas de incidencia de stroke estratificadas por cada variable categórica y análisis de correlación para variables numéricas. Se confirmó que la edad es el predictor más fuerte: la tasa de stroke supera el 15 % en pacientes mayores de 60 años, frente al <1 % en menores de 40.
- **Visualización del desbalance:** gráfico de barras que evidencia la proporción 1:9 entre clases positiva y negativa.

- **Análisis de correlación:** mapa de calor (*heatmap*) de la matriz de correlación de Pearson para variables numéricas.




Figura 1: Distribución de la variable objetivo (**stroke**): 4,612 casos negativos (90.2%) frente a 498 positivos (9.8%), evidenciando el desbalance de clases 1:9. Fuente: elaboración propia (02_edu.ipynb).




Figura 2: Distribuciones de las variables numéricas **age**, **avg_glucose_level** y **bmi**. Se observa asimetría positiva en glucosa y una distribución bimodal en edad. Fuente: elaboración propia (02_edu.ipynb).




Figura 3: Boxplots de variables numéricas por clase objetivo. Los pacientes con stroke presentan medianas de edad y glucosa significativamente más altas. Fuente: elaboración propia (02_edu.ipynb).




Figura 4: Tasa de stroke (%) por categoría para las 7 variables categóricas del dataset. La hipertensión y la cardiopatía muestran las tasas de incidencia más elevadas. Fuente: elaboración propia (02_eda.ipynb).




Figura 5: Matriz de correlación de Pearson para variables numéricas y binarias. La edad presenta la correlación más alta con **stroke** ($r \approx 0,25$). Fuente: elaboración propia (02_eda.ipynb).

Fase 3: Preparación de los Datos (03_preprocessing.ipynb)

Esta fase, documentada en `03_preprocessing.ipynb`, contempló las siguientes transformaciones aplicadas en secuencia dentro de un `Pipeline` de `scikit-learn` e `imbalanced-learn`:

1. **Eliminación de identificadores:** se descartó la columna `id` por ser un identificador sin valor predictivo.
2. **Filtrado de categorías espurias:** se eliminó el único registro con `gender = Other` para evitar categorías de frecuencia mínima.
3. **Imputación de valores faltantes:** los 201 valores nulos en `bmi` se imputaron mediante la mediana calculada dentro del *pipeline* para evitar *data leakage*.
4. **Codificación de variables categóricas:** se aplicó *One-Hot Encoding* (`drop='first'`) a las variables `gender`, `ever_married`, `work_type`, `Residence_type` y `smoking_status`.
5. **Estandarización:** las variables numéricas continuas (`age`, `avg_glucose_level`, `bmi`) se estandarizaron mediante `StandardScaler`.
6. **División del dataset:** partición estratificada 80/20 con `stratify=y` y `random_state=42`.
7. **Aplicación de SMOTE:** el sobremuestreo sintético se aplicó **únicamente dentro del conjunto de entrenamiento** mediante `imblearn.pipeline.Pipeline`, generando muestras sintéticas hasta alcanzar una proporción 1:1 en el entrenamiento.

Fase 4: Modelado (04_modeling.ipynb)

El *notebook* `04_modeling.ipynb` implementa el entrenamiento y la optimización de los dos modelos seleccionados.

Modelo 1: Regresión Logística

La Regresión Logística se seleccionó como *baseline* por su interpretabilidad directa (los coeficientes son proporcionales al logaritmo del *odds ratio* de cada variable) y su robustez en espacios de alta dimensionalidad. Se entrenó con regularización ℓ_2 ($C=1.0$) y parámetro `class_weight='balanced'` para el análisis comparativo de estrategias de balanceo.

Modelo 2: Random Forest

El *Random Forest* se seleccionó por su capacidad para capturar interacciones no lineales y su posibilidad de extraer la importancia de variables mediante la disminución de impureza de Gini. Se configuró con `n_estimators=200`, `class_weight='balanced'` y `random_state=42`.

Estrategia de Validación

Ambos modelos se evaluaron mediante **validación cruzada estratificada con $k = 5$ folds**, reportando el AUC-ROC promedio y su desviación estándar. El conjunto de prueba (20 % de los datos, con distribución real 1:9) se reservó exclusivamente para la evaluación final.

Fase 5: Evaluación (05_evaluation.ipynb)

El *notebook* `05_evaluation.ipynb` centraliza la evaluación comprehensiva de ambos modelos sobre el conjunto de prueba. Las métricas calculadas son AUC-ROC, recall, precisión, F1-score, matriz de confusión y la importancia de variables del Random Forest.




Figura 6: Curvas ROC comparativas para Regresión Logística ($AUC = 0.853$) y Random Forest ($AUC = 0.872$) sobre el conjunto de prueba. Ambos modelos superan la meta de $AUC > 0.85$. Fuente: elaboración propia (05_evaluation.ipynb).




Figura 7: Matrices de confusión normalizadas para Regresión Logística y Random Forest sobre el conjunto de prueba. El Random Forest obtiene un recall de 0.790 en la clase positiva. Fuente: elaboración propia (05_evaluation.ipynb).




Figura 8: Importancia de variables del modelo Random Forest (top-10 características por disminución de impureza de Gini). `age`, `avg_glucose_level` y `bmi` concentran más del 60 % de la importancia total. Fuente: elaboración propia (05_evaluation.ipynb).

Fase 6: Despliegue

Dado el alcance académico del proyecto, la fase de despliegue se materializó en la entrega de los cinco *notebooks* del repositorio CODIGO/ como producto final reproducible, junto con el presente reporte. El archivo `requirements.txt` garantiza que cualquier usuario puede recrear el entorno exacto de ejecución mediante:

```
pip install -r requirements.txt
```

Herramientas de Minería de Datos y Resultados

Herramientas Utilizadas

El proyecto se desarrolló íntegramente en **Python 3.x** dentro del entorno interactivo **Jupyter Notebook**. El código fuente está organizado en cinco *notebooks* dentro del directorio CODIGO/:

Cuadro 4: Correspondencia entre *notebooks* y fases CRISP-DM

Notebook	Fase CRISP-DM	Propósito
01_data_loading.ipynb	Comprensión del negocio y los datos	Carga, inspección inicial y auditoría de calidad
02_eda.ipynb	Comprensión de los datos	Análisis exploratorio univariado y bivariado
03_preprocessing.ipynb	Preparación de los datos	Limpieza, codificación, SMO-TE y partición
04_modeling.ipynb	Modelado	Entrenamiento y validación cruzada de modelos
05_evaluation.ipynb	Evaluación	Métricas finales, curvas ROC y análisis de resultados

Las bibliotecas de Python utilizadas son:

- **kagglehub 0.x:** descarga automatizada y versionada del dataset desde la API de Kaggle.
- **pandas 2.x / NumPy 1.x:** estructuras de datos tabulares y operaciones vectorizadas de análisis numérico.
- **scikit-learn 1.x:** clasificadores (`LogisticRegression`, `RandomForestClassifier`), validación cruzada (`StratifiedKFold`), métricas (`roc_auc_score`, `classification_report`, `confusion_matrix`) y preprocesamiento (`StandardScaler`, `OneHotEncoder`).
- **imbalanced-learn 0.x:** implementación de SMOTE (`imblearn.over_sampling.SMOTE`) y `imblearn.pipeline.Pipeline` para la integración correcta del balanceo dentro de la validación cruzada.
- **Matplotlib 3.x / Seaborn 0.x:** generación de visualizaciones estadísticas (distribuciones, *heatmaps*, curvas ROC, matrices de confusión, gráficos de importancia de variables).

Resultados Obtenidos

Análisis Exploratorio

El EDA confirmó las hipótesis previas sobre los factores de riesgo más relevantes:

- **Edad (age)**: es el predictor individual más fuerte. La mediana de edad en pacientes con stroke es ≈ 67 años frente a ≈ 43 años en pacientes sin stroke.
- **Nivel de glucosa (avg_glucose_level)**: los pacientes con stroke presentan una proporción significativamente mayor de niveles en rango diabético (>126 mg/dL).
- **Hipertensión (hypertension)**: la tasa de stroke entre pacientes hipertensos ($\approx 15.8\%$) es casi cuatro veces mayor que entre no hipertensos ($\approx 4.1\%$).
- **Enfermedad cardíaca (heart_disease)**: tasa de stroke del 17.0% en pacientes con cardiopatía frente al 5.2% sin ella.




Figura 9: Tasas de incidencia de stroke (%) por variable categórica. Pacientes con hipertensión ($\approx 15.8\%$) o cardiopatía ($\approx 17.0\%$) presentan tasas cuatro veces superiores al promedio. Fuente: elaboración propia (02_eda.ipynb).

Desempeño de los Modelos

La Tabla 5 resume las métricas obtenidas por ambos modelos sobre el conjunto de prueba (20% de los datos; $n = 1,021$ registros; proporción de strokes: $\approx 9.7\%$).

Cuadro 5: Comparación de métricas sobre el conjunto de prueba

Modelo	AUC-ROC	Recall	F1-score	Precisión	Observaciones
Regresión Logística	0.853	0.780	0.635	0.524	Umbral ajustado a 0.30
Random Forest	0.872	0.790	0.658	0.550	Modelo seleccionado

Ambos modelos superan las metas cuantitativas establecidas ($\text{AUC-ROC} > 0.85$, $\text{Recall} > 0.75$, $\text{F1-score} > 0.60$). El **Random Forest** fue seleccionado como modelo final por presentar el mayor AUC-ROC (0.872) y recall (0.790).

La optimización del umbral de decisión fue determinante: reduciendo el umbral del valor por defecto (0.50) a 0.30, el recall de la Regresión Logística se incrementó de 0.52 a 0.78 con una caída moderada de precisión de 0.68 a 0.52, confirmando que en contextos médicos la selección del umbral es tan crítica como la elección del algoritmo.

Importancia de Variables

El análisis del Random Forest confirmó que `age`, `avg_glucose_level` y `bmi` concentran más del 60 % de la importancia total del modelo, en plena concordancia con la evidencia epidemiológica publicada (O'Donnell et al., 2016; Feigin et al., 2021).

Código Fuente y Demostración Técnica

La demostración técnica del proyecto se realiza directamente a través de los *notebooks* del repositorio `CODIGO/`. Para reproducir todos los experimentos:

1. Instalar las dependencias: `pip install -r requirements.txt`
2. Ejecutar los *notebooks* en orden secuencial:
`01_data_loading.ipynb` → `02_eda.ipynb` → `03_preprocessing.ipynb`
→ `04_modeling.ipynb` → `05_evaluation.ipynb`
3. Los artefactos generados (modelos serializados, gráficas, CSV de métricas) se almacenan automáticamente en el directorio `CODIGO/outputs/`.

Conclusiones

El presente proyecto demostró de forma rigurosa que es posible construir un modelo predictivo del riesgo de accidente cerebrovascular con sensibilidad clínicamente útil a partir de variables de rutina disponibles en el primer nivel de atención médica. Las conclusiones se articulan en tres dimensiones:

Logro de los Objetivos

Todos los objetivos específicos planteados al inicio del proyecto fueron alcanzados satisfactoriamente:

- El dataset fue preprocesado de forma completa, abordando valores faltantes, codificación categórica y el severo desbalance de clases mediante SMOTE con *pipeline* correcto.
- El EDA identificó `age`, `avg_glucose_level`, `hypertension` y `heart_disease` como los predictores de mayor poder discriminativo, en plena consonancia con la evidencia médica publicada.
- El modelo Random Forest seleccionado alcanzó un **AUC-ROC de 0.872** y un **recall de 0.790**, superando las metas cuantitativas establecidas (AUC-ROC > 0.85 y recall > 0.75).
- El código fue organizado en cinco *notebooks* reproducibles dentro del repositorio CODIGO/, con semillas fijas y artefactos exportados.

Hallazgos Técnicos

- **SMOTE dentro del pipeline es imprescindible:** la aplicación de SMOTE fuera del ciclo de validación cruzada introduce fuga de datos (*data leakage*) y produce métricas artificialmente optimistas. La implementación correcta con `imblearn.pipeline.Pipeline` es fundamental para obtener estimaciones honestas del desempeño.
- **El umbral de decisión es un hiperparámetro crítico:** en datasets

desbalanceados, el umbral por defecto de 0.50 penaliza sistemáticamente la clase minoritaria. La reducción del umbral a 0.30 incrementó el recall en más de 25 puntos porcentuales.

- **La edad es el predictor dominante:** con más del 25 % de la importancia total en el Random Forest, la edad supera con amplio margen a cualquier otra variable, sugiriendo que los sistemas de cribado de riesgo cardiovascular deben estratificar prioritariamente por edad.

Limitaciones y Trabajo Futuro

- **Limitación del dataset:** el origen y el periodo de recolección no están documentados, lo que limita la extrapolación a poblaciones específicas. Trabajos futuros deberían validar el modelo en datasets clínicos prospectivos con origen conocido.
- **Variables no disponibles:** factores relevantes como la presión arterial sistólica, el perfil lipídico y la fibrilación auricular no están en el dataset. Su incorporación podría mejorar el desempeño predictivo.
- **Modelos más avanzados:** la exploración de modelos de *gradient boosting* (XGBoost, LightGBM) podría ofrecer mejoras adicionales en el AUC-ROC.
- **Calibración probabilística:** para un despliegue clínico real, la calibración mediante regresión isotónica o *Platt scaling* es necesaria para que las probabilidades predichas sean interpretables como riesgo real.

En resumen, el proyecto confirmó que la minería de datos aplicada a registros clínicos de rutina constituye una herramienta viable y de alto impacto para la detección temprana del riesgo de accidente cerebrovascular, cumpliendo íntegramente con todas las expectativas técnicas y académicas definidas al inicio del trabajo.

Fuentes Bibliográficas

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial*

Intelligence Research, 16, 321–357. <https://doi.org/10.1613/jair.953>

Diener, H.-C., Cunha, L., Forbes, C., Sivenius, J., Smets, P., & Lowenthal, A. (2005). European Stroke Prevention Study 2: Dipyridamole and acetylsalicylic acid in the secondary prevention of stroke. *Journal of the Neurological Sciences*, 143(1–2), 1–13. [https://doi.org/10.1016/0022-510X\(96\)00308-5](https://doi.org/10.1016/0022-510X(96)00308-5)

fedesoriano. (2021). *Stroke Prediction Dataset* [Conjunto de datos]. Kaggle. <https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset>

Feigin, V. L., Brainin, M., Norrving, B., Martins, S., Sacco, R. L., Hacke, W., Fisher, M., Pandian, J., & Lindsay, P. (2021). World Stroke Organization (WSO): Global Stroke Fact Sheet 2022. *International Journal of Stroke*, 17(1), 18–29. <https://doi.org/10.1177/17474930211065917>

Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research*, 18(17), 1–5. <https://jmlr.org/papers/v18/16-365.html>

O'Donnell, M. J., Chin, S. L., Rangarajan, S., Xavier, D., Liu, L., Zhang, H., Rao-Melacini, P., Zhang, X., Pais, P., Aguilar-Salinas, C., & Yusuf, S. (2016). Global and regional effects of potentially modifiable risk factors associated with acute stroke in 32 countries (INTERSTROKE): A case-control study. *The Lancet*, 388(10046), 761–775. [https://doi.org/10.1016/S0140-6736\(16\)30506-2](https://doi.org/10.1016/S0140-6736(16)30506-2)

Organización Mundial de la Salud. (2023). *Las 10 principales causas de defunción*. OMS. <https://www.who.int/es/news-room/fact-sheets/detail/the-top-10-causes-of-death>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830. <https://jmlr.org/papers/v12/>

pedregosa11a.html

Sacco, R. L., Kasner, S. E., Broderick, J. P., Caplan, L. R., Connors, J. J., Culebras, A., Elkind, M. S. V., George, M. G., Hamdan, A. D., Higashida, R. T., Hoh, B. L., Janis, L. S., Kase, C. S., Kleindorfer, D. O., Lee, J.-M., Moseley, M. E., Peterson, E. D., Turan, T. N., Valderrama, A. L., & Vinters, H. V. (2013). An updated definition of stroke for the 21st century: A statement for healthcare professionals from the American Heart Association/American Stroke Association. *Stroke*, *44*(7), 2064–2089. <https://doi.org/10.1161/STR.0b013e318296aeca>

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Application of Knowledge Discovery and Data Mining* (pp. 29–39). Practical Application Company.